

- ① Demuestre que si los vectores no nulos p_1, p_2, \dots, p_ℓ satisfacen que: $p_i^T A p_j = 0 \quad \forall i \neq j$ y A es simétrica ~~antisimétrica~~ y positiva definida entonces los vectores son linealmente independientes.

Demo: Para mostrar que el conjunto de vectores $\{p_1, \dots, p_j, \dots, p_\ell\}$ es linealmente independiente basta mostrar que:

$$\lambda_1 p_1 + \dots + \lambda_j p_j + \dots + \lambda_\ell p_\ell = 0 \iff \lambda_i = 0 \quad \forall i \in \{1, \dots, \ell\}$$

Multiplíquese por $p_j^T A$ por ambos lados tenemos que:

$$p_j^T A (\lambda_1 p_1 + \dots + \lambda_j p_j + \dots + \lambda_\ell p_\ell) = 0$$

$$\iff \lambda_1 \cancel{p_j^T A} p_1 + \dots + \lambda_j p_j^T A p_j + \dots + \lambda_\ell \cancel{p_j^T A} p_\ell = 0$$

$$\iff \lambda_j p_j^T A p_j = 0$$

Como A es simétrica positiva definida entonces: $p_j^T A p_j > 0$

Con lo cual:

$$\lambda_j p_j^T A p_j = 0 \iff \lambda_j = 0$$

Y este razonamiento es válido para toda $j \in \{1, \dots, \ell\}$

$$\therefore \sum_{i=1}^{\ell} \lambda_i p_i = 0 \iff \lambda_i = 0 \quad \forall i \in \{1, \dots, \ell\}$$

$\therefore \{p_1, \dots, p_\ell\}$ es un conjunto linealmente independiente \square

② Dado este resultado, ¿Por qué el gradiente conjugado converge en a lo más n iteraciones?

Demo: Si el dominio de la función a optimizar es un subconjunto de \mathbb{R}^n entonces sabemos que n vectores linealmente independientes son suficientes para generar a todo \mathbb{R}^n y, en particular, a todo el dominio de la función.

Dado que el conjunto inicial de vectores $\{p_0, \dots, p_{n-1}\}$ es l.i entonces podemos afirmar que:

$$(x^* - x_0) = \lambda_1 p_1 + \dots + \lambda_n p_n \text{ para una correcta elección de } \lambda_i's.$$

¿Cuál es la elección de λ_i correcta?


Podemos ver cuál es la elección de λ_j correcta si multiplicamos por $p_j^T A$ en ambos lados:

$$p_j^T A (x^* - x_0) = \lambda_j p_j^T A p_j$$

$$\Leftrightarrow \lambda_j = \frac{p_j^T A (x^* - x_0)}{p_j^T A p_j} = \frac{p_j^T A ((x^* - x_j) + (x_j - x_0))}{p_j^T A p_j}$$

$$= \frac{p_j^T A (x^* - x_j)}{p_j^T A p_j} = \frac{p_j^T (b - A x_j)}{p_j^T A p_j} = \frac{-p_j^T p_j}{p_j^T A p_j} !!$$

Esta elección de λ_j coincide con la propuesta del método de Gradiente Conjugado.

Conclusión: Como las direcciones son l.i entonces podemos escribir al vector $(x^* - x_0)$ como una combinación lineal de esas n direcciones y eligiendo las λ_i propuestas logramos escribir al vector $(x^* - x_0)$ en términos de a lo más n vectores, que requieren a lo más n pasos. 

1) Muestra que la condición fuerte de Wolfe implica la condición de curvatura.

Recordemos que $|a| \leq b \Rightarrow -b \leq a \leq b$

~~Entonces~~

Entonces podemos afirmar lo siguiente:

$$|\nabla f(x_k + \alpha_k p_k)^T p_k| \leq c_2 |\nabla f(x_k)^T p_k| \rightarrow \text{Wolfe fuerte}$$

$$\Leftrightarrow -c_2 |\nabla f(x_k)^T p_k| \leq \nabla f(x_k + \alpha_k p_k)^T p_k \leq c_2 |\nabla f(x_k)^T p_k|$$

En particular:

$$\nabla f(x_k + \alpha_k p_k)^T p_k \geq -c_2 |\nabla f(x_k)^T p_k|$$

Y como p_k es dirección de descenso:

$$\nabla f(x_k + \alpha_k p_k)^T p_k \geq c_2 \nabla f_k^T p_k$$

Restando $\nabla f_k^T p_k$ de ambos lados con $c_2 < 1$, tenemos que:

$$\nabla f(x_k + \alpha_k p_k)^T p_k - \nabla f_k^T p_k = (c_2 - 1) \nabla f_k^T p_k > 0$$

Multipliquemos en ambos lados por α_k :

$$\nabla f(x_k + \alpha_k p_k)^T \overbrace{\alpha_k p_k}^{s_k} - \nabla f_k^T \alpha_k p_k = (c_2 - 1) \nabla f_k^T \alpha_k p_k > 0$$

$$\Leftrightarrow \underbrace{s_k (\nabla f(x_k + \alpha_k p_k) - \nabla f_k)}_{g_k} = (c_2 - 1) \nabla f_k^T s_k > 0$$

$$\Leftrightarrow s_k^T \cdot g_k > 0 \quad \square$$

② Verifique que B_{k+1} y H_{k+1} son inversa una de la otra.

$$B_{k+1} H_{k+1} = B_{k+1} ((I - \varphi_k S_k Y_k^T) H_k (I - \varphi_k Y_k S_k^T) + \varphi_k S_k S_k^T)$$

$$= (B_{k+1} - \varphi_k \underline{B_{k+1} S_k Y_k^T}) H_k (I - \varphi_k Y_k S_k^T) + \varphi_k B_{k+1} S_k S_k^T$$

$$= (B_{k+1} - \varphi_k Y_k Y_k^T) H_k (I - \varphi_k Y_k S_k^T) + \varphi_k Y_k S_k S_k^T$$

$$= \left(B_k - \frac{B_k S_k S_k^T B_k}{S_k^T B_k S_k} - \varphi_k Y_k Y_k^T \right) H_k (I - \varphi_k Y_k S_k^T) + \varphi_k Y_k S_k S_k^T$$

$$= \left(B_k - \frac{B_k S_k S_k^T B_k}{S_k^T B_k S_k} \right) H_k (I - \varphi_k Y_k S_k^T) + \varphi_k Y_k S_k S_k^T$$

$$= \left(I - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} \right) (I - \varphi_k Y_k S_k^T) + \varphi_k Y_k S_k S_k^T$$

$$= \underbrace{I - \varphi_k Y_k S_k^T}_{\text{cancel}} - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} + \frac{B_k S_k S_k^T}{S_k^T B_k S_k} (\varphi_k Y_k S_k^T) + \varphi_k Y_k S_k S_k^T$$

$$= I - \varphi_k Y_k S_k^T - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} + \frac{1}{S_k^T Y_k} \frac{B_k S_k (S_k^T Y_k) S_k^T}{S_k^T B_k S_k} + \varphi_k Y_k S_k S_k^T$$

$$= I - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} - \cancel{\varphi_k Y_k S_k^T} + \frac{B_k S_k S_k^T}{S_k^T B_k S_k} + \cancel{\varphi_k Y_k S_k^T}$$

$$= I \quad \square$$